Caso de Estudio I - Wine Quality

Isaac Castillo Vega

Ignacio Castillo Vega

LEAD University

Minería de Datos I

Profesor Juan Murillo Morera

Marzo 2026

1. **Análisis de Componentes Principales (ACP)**

El Análisis de Componentes Principales o PCA (Principal Component Analysis), por sus siglas en inglés. Es un algoritmo que toma un enfoque relacionado a la reducción de dimensionalidad. Usualmente es utilizado para comprimir una cantidad inmensa de variables a una cantidad manejable y a la vez lograr mantener la mayoría de su información.

Es útil en muchas ramas, algunas de estas son:

- **Procesamiento de Video e Imágenes:** Reconocimiento facial, compresión de imágenes y reducción de ruido. Por medio de la reducción de la dimensionalidad, se extraen solamente los patrones y características más importantes.
- **Bioinformática y Área Genómica:** Análisis de expresión de los genes, identificación de subtipos de enfermedades, y entendimiento de la relación entre genes.
- **Datos Financieros:** Identificación de patrones y reducción de dimensionalidad de datos financieros, ayuda en la optimización de portafolios, manejo de riesgo e identificación de factores que influyen en los mercados financieros.
- **Minería de Texto:** Analizar datasets grandes, como colecciones de documentos o datos de redes sociales.

Algunos beneficios:

- Reducción de la dimensionalidad en datasets con alta dimensionalidad al identificar un grupo de componentes principales que nos dan la información más importantes en los datos, y así reduciendo la complejidad computacional, requisitos de memoria y una mejora en la eficiencia del algoritmo.
- Extracción de características más importantes en datos complejos, permitiendo una mejor interpretación y entendimiento de la estructura de datos.
- Reducción de ruido al enfocarse en los componentes con los eigenvalues más altos.

- Permite visualizar datos con alta dimensionalidad en un espacio de menor dimensionalidad; esto nos permite visualizar clusters, patrones y relaciones que existan en los datos. Ayudando en el EDA o Análisis Exploratorio de Datos.

Matemáticamente, el PCA se basa en la descomposición espectral de la matriz de covarianza del dataset. El objetivo es encontrar vectores propios (eigenvectors) que definan las direcciones de máxima varianza en los datos. Cada componente principal corresponde a un eigenvector asociado a un eigenvalue. Los eigenvalues indican cuánta varianza del dataset es explicada por cada componente principal.

El ACP es muy bueno pero también tiene algunas limitaciones.

- El ACP asume que los datos están linealmente relacionados a los componentes principales. Entonces si los datos tienen relaciones complejas no lineales, el ACP tal vez no logre capturar toda la información relevante, en estos casos otros métodos o algoritmos serían mejores.
- Puede existir una pérdida de la interpretabilidad de los datos, ya que los componentes principales normalmente se convierten en una combinación de las variables originales; lo que puede hacer la interpretación más laboriosa o difícil.
- El ACP se enfoca en capturar la información más importante en los datos, esto causa que haya pérdidas de información durante el proceso de reducción de dimensionalidad; y que las interpretaciones nuevas de menor dimensionalidad no retengan todos los detalles presentes originalmente.
- Ya que la selección de componentes es subjetiva se pueden presentar problemas al hacer este paso. Si la elección de componentes es muy pequeña, pueden existir pérdidas de información y si es muy grande nos encontramos con overfitting o complejidad innecesaria a la hora de representar los datos.

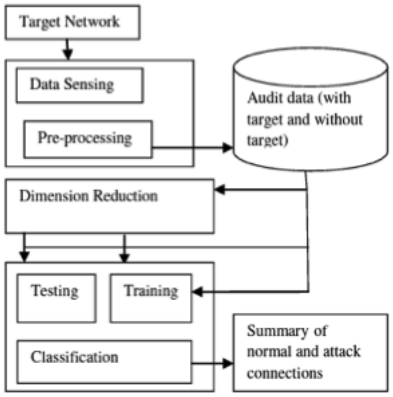

Fig 1 System Design

2. **Agrupamiento Jerárquico (HAC)**

El clustering jerárquico aglomerativo (Hierarchical Agglomerative Clustering, HAC) es un método de aprendizaje no supervisado que organiza los datos en una estructura jerárquica de agrupamientos basada en la similitud entre observaciones. Este tipo de algoritmo permite identificar patrones naturales dentro de un conjunto de datos sin necesidad de utilizar etiquetas previamente definidas (Han et al., 2012).

A diferencia de otros métodos de clustering, HAC no requiere definir previamente el número de clusters. En su lugar, el algoritmo construye una jerarquía completa de agrupamientos, la cual puede analizarse posteriormente para determinar el número de clusters más apropiado según la estructura de los datos (Bonald, 2016).

El resultado del algoritmo se representa mediante un dendrograma, que es una representación gráfica en forma de árbol que muestra cómo se van fusionando los clusters a medida que aumenta el nivel de distancia o disimilitud entre ellos.

El funcionamiento del algoritmo sigue un enfoque aglomerativo, lo que significa que el proceso comienza considerando cada observación del dataset como un cluster independiente. Posteriormente, en cada iteración se identifican los dos clusters más cercanos entre sí y se fusionan en un nuevo cluster. Este proceso continúa hasta que todas las observaciones terminan formando un único cluster (Han et al., 2012).

Para determinar la similitud entre las observaciones, el algoritmo utiliza medidas de distancia. Una de las más utilizadas en datasets numéricos es la distancia euclidiana, la cual mide la distancia geométrica entre dos puntos en un espacio multidimensional.

Cuando los clusters contienen múltiples observaciones, es necesario definir cómo se calcula la distancia entre clusters completos. Para esto se utilizan diferentes métodos de enlace (linkage).

Entre los métodos más comunes se encuentran:

- **Single Linkage**

  Define la distancia entre dos clusters como la distancia mínima entre cualquier par de observaciones pertenecientes a cada cluster. Este método puede detectar estructuras alargadas en los datos, aunque puede generar el fenómeno conocido como chaining, donde los clusters se conectan a través de puntos intermedios.

- **Complete Linkage**
  Define la distancia entre clusters como la distancia máxima entre observaciones de cada cluster. Este enfoque suele generar clusters más compactos y bien separados.
- **Average Linkage**
  Calcula la distancia entre clusters utilizando el promedio de todas las distancias entre pares de puntos pertenecientes a los clusters que se comparan.
- **Ward Linkage**
  El método Ward busca minimizar la varianza dentro de los clusters al momento de realizar cada fusión. Este enfoque tiende a generar clusters compactos y es uno de los métodos más utilizados en análisis de clustering jerárquico.

Una vez que el algoritmo genera la estructura jerárquica de los clusters, esta puede visualizarse mediante un dendrograma. En este gráfico, el eje horizontal representa las observaciones del dataset, mientras que el eje vertical representa la distancia a la que los clusters se fusionan.
El dendrograma permite identificar posibles agrupamientos naturales en los datos. Al realizar un corte horizontal en el árbol, se puede determinar el número de clusters que mejor representa la estructura del dataset.
En el caso del presente estudio sobre Wine Quality, el dendrograma fue construido utilizando el método Ward, el cual busca minimizar la varianza dentro de los clusters. Al analizar el dendrograma generado, se observa que los clusters comienzan a fusionarse a distancias mayores a partir de aproximadamente 40–50 unidades de distancia.
Esto sugiere que existe una estructura de agrupamiento en el dataset que podría interpretarse aproximadamente como cuatro clusters principales, cada uno representando vinos con características químicas similares.
Este tipo de análisis permite explorar la estructura interna del dataset y detectar patrones o agrupamientos naturales entre las observaciones antes de aplicar otros métodos de clustering o técnicas adicionales de reducción de dimensionalidad.

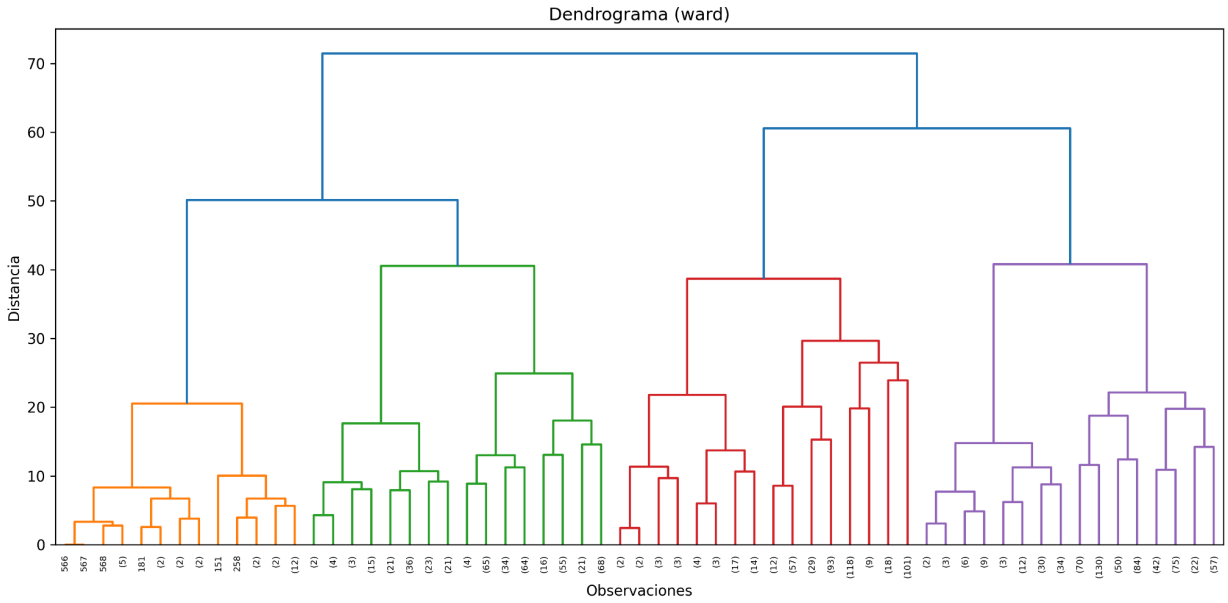
Dendrograma (ward)
Distancia
0
10
20
30
40
50
60
70
Observaciones
566
567
568
(5)
181
(2)
(2)
(2)
151
258
(2)
(2)
(12)
(2)
(4)
(3)
(15)
(21)
(36)
(23)
(21)
(4)
(65)
(34)
(64)
(16)
(55)
(21)
(68)
(2)
(2)
(3)
(3)
(4)
(3)
(17)
(14)
(12)
(57)
(29)
(93)
(118)
(9)
(18)
(101)
(2)
(3)
(6)
(9)
(3)
(12)
(30)
(34)
(70)
(130)
(50)
(84)
(42)
(75)
(22)
(57)

3. **Agrupamiento por Centroides (Kmeans)**

Algoritmo de clustering partitivo que agrupa datos en **k clusters**, donde ***k*** se especifica previamente. Cada cluster está representado por su centroide (media de los puntos del cluster).

¿Cómo funciona?

1. Se agrupan los datos en **k** subgrupos en los que el valor de **k** es predeterminado.
2. De manera aleatoria se escogen **k** puntos como centroides del cluster.
3. Asignar el objeto del dataset al cluster con el centroide más cercano de acuerdo a un cálculo hecho por la función de distancia Euclidiana.
4. Encontrar el centroide o media de todos los objetos en cada cluster.
5. Replicar los pasos tres y cuatro hasta que haya la misma cantidad de objetos en cada cluster.

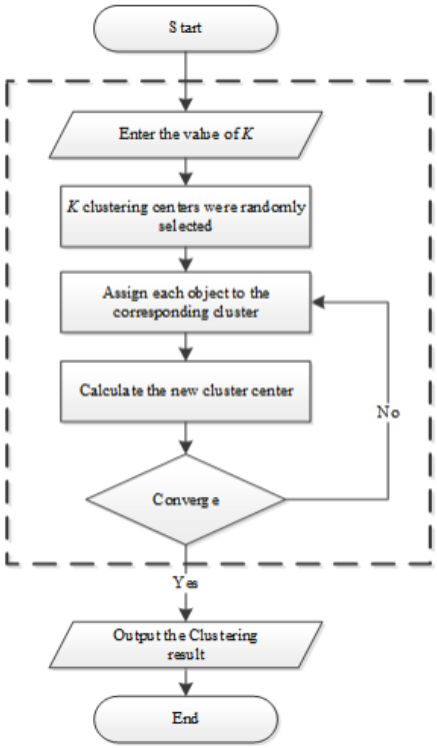

K-means tiene varios beneficios:

- Su simpleza.
- La rapidez.
- Su eficacia para procesamiento de datasets grandes.
- Es escalable.

Pero también tiene varios obstáculos, el principal es la necesidad de **k**, tener que escoger un número lo hace dependiente de que la persona implementándolo logre acertar buenos parámetros. Si se seleccionan parámetros malos; la eficacia, rapidez y el rendimiento del algoritmo se verán afectados.
K-means es bastante susceptible a los outliers (valores atípicos que se alejan significativamente del resto de los datos). Esto ocurre porque el algoritmo calcula los centroides usando la media aritmética de todos los puntos en cada cluster, por lo que un solo outlier puede desplazar considerablemente la posición del centroide, afectando la calidad del agrupamiento.
Por último, K-means sólo puede ser utilizado para datos numéricos, ya que calcula distancias euclidianas, así que si se quisiera utilizar para datos no numéricos, tendríamos que buscar formas para convertirlos en binarios cómo usando one hot encoding (técnica de preprocesamiento que convierte datos categóricos en binarios: 0 y 1), lo que dificulta significativamente el procesamiento de datos.

4. t-SNE

El algoritmo t-SNE(t-distributed Stochastic Neighbor Embedding) es una técnica de reducción de dimensionalidad no lineal utilizada principalmente para la visualización de datasets de alta dimensionalidad.
Está diseñado para preservar las relaciones locales entre las observaciones, permitiendo representar datos complejos en espacios de menor dimensión (dos o tres dimensiones).

El objetivo principal de t-SNE es transformar las distancias entre puntos en el espacio de alta dimensión en probabilidades que representen similitudes entre observaciones. Posteriormente, el algoritmo busca una representación en un espacio de menor dimensión que mantenga esas relaciones de similitud lo más fielmente posible.

El proceso del algoritmo puede resumirse de la siguiente manera:

1. El algoritmo calcula las distancias entre todas las observaciones en el espacio original de alta dimensionalidad.
2. Estas distancias se convierten en probabilidades que representan la similitud entre los puntos.
3. Posteriormente, el algoritmo genera una representación inicial en un espacio de menor dimensión (generalmente 2D o 3D).
4. Mediante un proceso iterativo de optimización, t-SNE ajusta las posiciones de los puntos en el espacio reducido para preservar las probabilidades de similitud calculadas originalmente.

Una de las principales características de t-SNE es que prioriza la preservación de la estructura local de los datos, lo que significa que puntos cercanos en el espacio original tenderán a permanecer cercanos en la representación de menor dimensión. Esto permite revelar clusters o agrupamientos naturales que pueden no ser evidentes utilizando técnicas lineales.

Entre los principales beneficios del algoritmo t-SNE se encuentran:

- Permite visualizar datasets de alta dimensionalidad en espacios bidimensionales o tridimensionales.
- Revela estructuras complejas y agrupamientos naturales en los datos.
- Facilita el análisis exploratorio de datos y la identificación de patrones ocultos.

Sin embargo, el algoritmo también presenta algunas limitaciones importantes. t-SNE puede ser computacionalmente costoso cuando se trabaja con datasets muy grandes. Además, los resultados pueden verse influenciados por parámetros como la perplexity, que controla el balance entre la preservación de relaciones locales y globales.

Otra característica importante es que t-SNE está diseñado principalmente para visualización, por lo que las distancias globales entre clusters pueden no representar con precisión las distancias originales entre las observaciones.

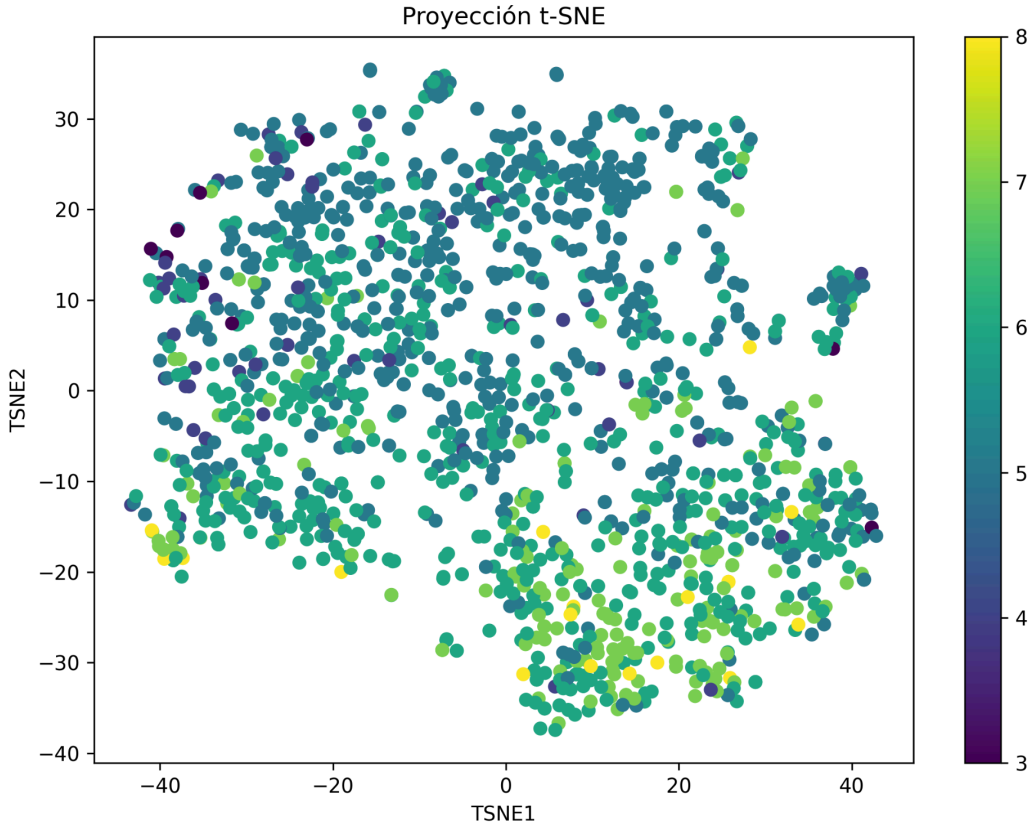

5. UMAP

El algoritmo UMAP (Uniform Manifold Approximation and Projection) es otra técnica de reducción de dimensionalidad que se utiliza para visualizar datasets complejos en espacios de menor dimensión. Este método se basa en principios de topología y teoría de grafos, y busca preservar tanto la estructura local como parte de la estructura global de los datos.

UMAP parte de la idea de que los datos se encuentran distribuidos sobre una estructura matemática conocida como manifold dentro del espacio de alta dimensionalidad. El algoritmo intenta aprender esa estructura y luego proyectarla en un espacio más pequeño manteniendo las relaciones importantes entre las observaciones.

El proceso del algoritmo consiste primero en construir un grafo que representa las relaciones de vecindad entre los puntos del dataset. Posteriormente, el algoritmo busca una representación en menor dimensión que conserve la estructura de ese grafo.

Una de las principales ventajas de UMAP es que suele ser más rápido que t-SNE y puede manejar datasets grandes de manera más eficiente. Además, tiende a preservar mejor la estructura global de los datos, lo que permite observar no solo clusters locales sino también relaciones más amplias entre grupos.

Entre los parámetros más importantes del algoritmo se encuentran n_neighbors, que controla cuántos vecinos se consideran para construir el grafo de proximidad, y min_dist, que regula qué tan separados o compactos pueden aparecer los clusters en la representación final.

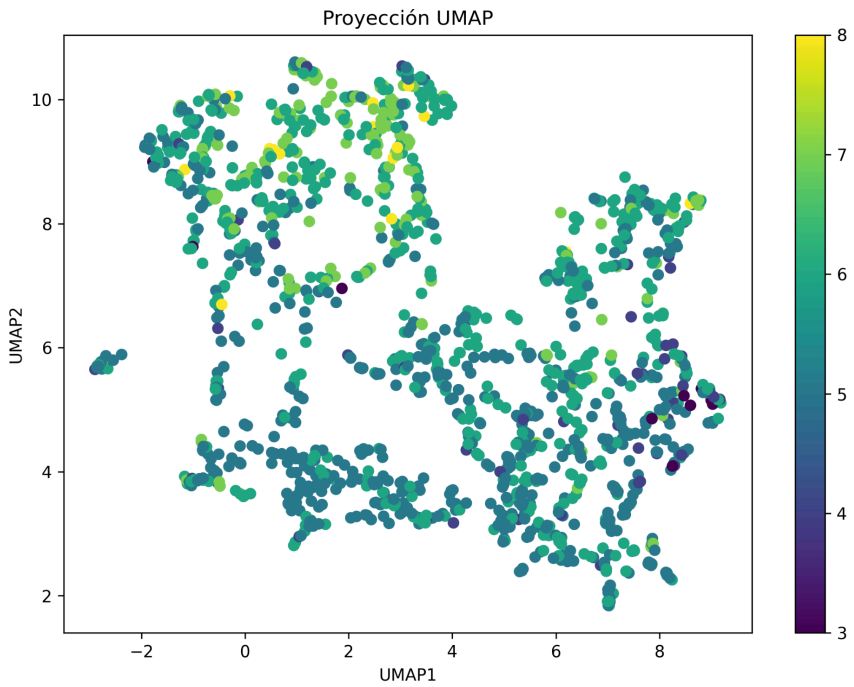

Mapa conceptual:

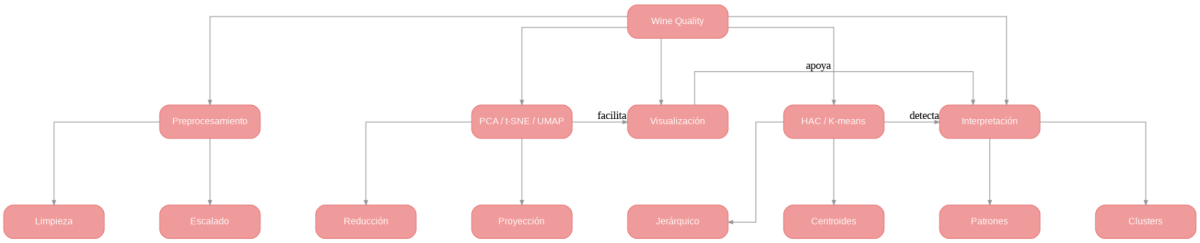

Referencias:

Bonald, T. (2016). Hierarchical clustering. Télécom Paris.
https://perso.telecom-paristech.fr/bonald/documents/hierarchy.pdf

Han, J., Kamber, M., & Pei, J. (2012). Data mining: Concepts and techniques (3rd ed.). Morgan Kaufmann.
https://github.com/chmx0929/UIUCclasses/blob/master/512DataMiningPrinciples/Data%20Mining%20-%20Concepts%20and%20Techniques%20%5B3rd%20ed.%5D%20-%20Jiawei%20Han%2C%20Micheline%20Kamber%2C%20Jian%20Pei.pdf

Murtagh, F., & Legendre, P. (2011). Ward's hierarchical clustering method: Clustering criterion and agglomerative algorithm.
https://arxiv.org/pdf/1111.6285

Ward, J. H. (1963). Hierarchical grouping to optimize an objective function. Journal of the American Statistical Association, 58(301), 236–244.
https://iv.cns.iu.edu/sw/data/ward.pdf

Ashabi, A., Sahibuddin, S. B., & Haghighi, M. S. (2021). The systematic review of K-means clustering algorithm. In ICNCC '20: Proceedings of the 2020 9th International Conference on Networks, Communication and Computing (pp. 13-21). Association for Computing Machinery. https://doi.org/10.1145/3447654.3447657

Bharadiya, J. P. (2023). A tutorial on principal component analysis for dimensionality reduction in machine learning. International Journal of Innovative Science and Research Technology,
https://ijisrt.com/a-tutorial-on-principal-component-analysis-for-dimensionality-reduction-in-machine-learning

Karamizadeh, S., Abdullah, S. M., Manaf, A. A., Zamani, M., & Hooman, A. (2013). An overview of principal component analysis. Journal of Signal and Information Processing, 4(3), 173-175. https://doi.org/10.4236/jsip.2013.43B031